



Compte rendu récapitulatif 14/11/2024 -05/12/2024

Ce qui a été fait :

1. Appréhender le jeu de données

Nous avons appréhender les 107 pdfs, ce sont tous des rapports annuels contenant une section dédiée à l'analyse financière, rédigés en anglais:

Voici le lien pour accéder à l'Excel partagé: [Artefact_bdd.xlsx](#)

Document Number	Number of Pages	Textuelles	Graphiques	Tableaux	Language	Source	Type d'information	date	Audit	Commentaires
35	66	✓	✓	✓	EN	Emerson	Report annuel	2014 KPMG		
36	66	✓	✓	✓	EN	Emerson	Report annuel	2015 KPMG		
37	24	✓	✓	✓	EN	Emerson	Report annuel	2016 KPMG		
38	92	✓	✓	✓	EN	Emerson	Report annuel	2017 KPMG		
39	68	✓	✓	✓	EN	Emerson	Report annuel	2018 KPMG		
40	71	✓	✓	✓	EN	Emerson	Report annuel	2019 KPMG		
41	80	✓	✓	✓	EN	Emerson	Report annuel	2020 KPMG		
42	88	✓	✓	✓	EN	Emerson	Report annuel	2021 KPMG		
43	99	✓	✓	✓	EN	Emerson	Report annuel	2022 KPMG		
44	96	✓	✓	✓	EN	Emerson	Report annuel	2023 KPMG		
45	75	✓	□	✓	EN	Energy	Report annuel	2014 EY		
46	75	✓	□	✓	EN	Energy	Report annuel	2014 Doublons		
47	61	✓	□	✓	EN	Energy	Report annuel	2015 BDO		
48	71	✓	□	✓	EN	Energy	Report annuel	2016 BDO		
49	73	✓	□	✓	EN	Energy	Report annuel	2017 BDO		
50	78	✓	□	✓	EN	Energy	Report annuel	2018 BDO		
51	71	✓	□	✓	EN	Energy	Report annuel	2019 BDO		
52	76	✓	□	✓	EN	Energy	Report annuel	2020 BDO		
53	77	✓	□	✓	EN	Energy	Report annuel	2021 BDO		
54	80	✓	□	✓	EN	Energy	Report annuel	2022 BDO		
55	90	✓	□	✓	EN	Energy	Report annuel	2023 BDO		++
56	68	✓	✓	✓	EN	Equity Trustees	Report annuel	2005 Deloitte		
57	108	✓	✓	✓	EN	Equity Trustees	Report annuel	2006 Deloitte		
58	112	✓	✓	✓	EN	Equity Trustees	Report annuel	2007 Deloitte		
59	84	✓	□	✓	EN	Equity Trustees	Report annuel	2008 Deloitte		
60	80	✓	□	✓	EN	Equity Trustees	Report annuel	2009 Deloitte		
61	80	✓	□	✓	EN	Equity Trustees	Report annuel	2010 Deloitte		
62	76	✓	□	✓	EN	Equity Trustees	Report annuel	2011 Deloitte		
63	80	✓	□	✓	EN	Equity Trustees	Report annuel	2012 Deloitte		
64	80	✓	□	✓	EN	Equity Trustees	Report annuel	2013 Deloitte		
65	84	✓	□	✓	EN	Equity Trustees	Report annuel	2014 Deloitte		
66	76	✓	□	✓	EN	Equity Trustees	Report annuel	2015 Deloitte		
67	88	✓	✓	✓	EN	Equity Trustees	Report annuel	2016 Deloitte		
68	57	✓	✓	✓	EN	Equity Trustees	Report annuel	2017 Deloitte		
69	120	✓	✓	✓	EN	Equity Trustees	Report annuel	2018 Deloitte		tableaux à l'envers
70	128	✓	✓	✓	EN	Equity Trustees	Report annuel	2019 Deloitte		

Figure 1: Extrait analyse des 107 documents

Graphiques	(Tous)			
Étiquettes de lignes	Moyenne de Number of Pages	Nbr de Graphiques	Nbr de Tableaux	Nbr d'info textuelles
1999	56	1	1	1
2000	60	1	1	1
2001	47,5	2	2	2
2002	61	2	2	2
2003	66	2	2	2
2004	61,5	2	2	2
2005	67,33333333	3	3	3
2006	80,66666667	3	3	3
2007	72,75	4	4	4
2008	65	4	4	4
2009	76,25	4	4	4
2010	71,75	4	4	4
2011	67	5	5	5
2012	68,6	5	5	5
2013	79	5	5	5
2014	79	6	6	6
2015	73,5	6	6	6
2016	71,83333333	6	6	6
2017	76,4	5	5	5
2018	84	5	5	5
2019	84	6	6	6
2020	94	6	6	6
2021	93,57142857	7	7	7
2022	95,57142857	7	7	7
2023	102,1666667	6	6	6
Total général	78,51401869	107	107	107

Figure 2: Analyse statistique BDD par années

Conclusion:

- **Moyenne de 78 pages** pour chaque document → **Chunking par page pourrait être intéressant**
- Chaque document contient des **informations tabulaires ainsi que des graphes** qui doivent pouvoir être exploité → **Besoin de RAG Vision et donc de modèle VLM!**
- **Type d'informations exploitables :**
 - Indicateurs de performance financière
 - Plans stratégiques et initiatives de croissance
 - Tendances sectorielles + conditions de marché
 - **Engagement ESG** → ex: Neutralité carbone d'Emerson et d'Equity Trustees
 - **Gestion des risques et gouvernance**

2. Recherche data set open source

1. Finance Alpaca - Hugging Face

(<https://huggingface.co/datasets/gbharti/finance-alpaca>)

- a. Offre un ensemble de données axé sur des informations financières de marché, incluant des cotations, des prix historiques et divers indicateurs financiers des actifs.
- b. cleaned up dataset : https://huggingface.co/datasets/gbharti/wealth-alpaca_lora
- c. GitHub repo avec des analyses de performance, des scripts d'entraînement et de génération de données, et des cahiers d'inférence: <https://github.com/gaurangbharti1/wealth-alpaca>

2. Financial Reports sec - Hugging Face

(<https://huggingface.co/datasets/JanosAudran/financial-reports-sec>)

- a. Fournit un accès libre aux rapports financiers des entreprises cotées aux États-Unis, publiés par la Securities and Exchange Commission (SEC). Inclut des informations telles que les bilans, comptes de résultats et autres déclarations réglementaires.
- b. Ce jeu de données contient les rapports annuels des entreprises publiques américaines déposés dans le système EDGAR de la SEC, de 1993 à 2020
- c. Chaque rapport annuel (dépôt 10-K) est divisé en 20 sections, et chaque section est découpée en phrases individuelles
- d. Les étiquettes de sentiment sont fournies pour chaque dépôt, basées sur la réaction du marché autour de la date de dépôt pour trois fenêtres temporelles différentes : $[t-1, t+1]$, $[t-1, t+5]$ et $[t-1, t+30]$
- e. Statistiques sommaires de l'ensemble de données à la fin du document

3. European Central Bank Statistical Data Warehouse (SDW)

(<https://data.ecb.europa.eu/data/datasets>)

- a. Fournit une vaste base de données statistiques sur les politiques économiques et monétaires de la Banque centrale européenne (BCE). Contient des données détaillées sur l'inflation, les taux d'intérêt, les agrégats monétaires, et d'autres indicateurs économiques de la zone euro et des États membres.

b. **Droits d'utilisation :**

- i. **Réutilisation** : Libre utilisation pour analyse, recherche et publications, tant que les données sont utilisées de manière à respecter les conditions de la BCE.
- ii. **Attribution** : Mention obligatoire de la BCE comme source, avec indication de la date d'accès ou de mise à jour.
- c. **Accès** : Disponible via API pour les chercheurs et développeurs inscrits.
- d. **Études** : Analyses qualitatives et quantitatives requises pour interpréter les tendances des politiques économiques.

4. **OECD Economic Outlook** (<https://www.oecd.org/en/data/datasets/oecd-DE.html>)

- a. Contient des prévisions économiques et analyses des tendances mondiales des pays membres de l'OCDE. Offre des indicateurs macroéconomiques, des prévisions de croissance, des taux de chômage, et des rapports sur les politiques économiques internationales.
- b. OECD Data Explorer - Finance and Investment : [https://data-explorer.oecd.org/?fs\[0\]=Topic%2C0|Finance and investment%23FIN%23&pg=0&fc=Topic&bp=true&snb=33](https://data-explorer.oecd.org/?fs[0]=Topic%2C0|Finance%20and%20investment%23FIN%23&pg=0&fc=Topic&bp=true&snb=33)
- c. **Accès** : Accessible via le site web de l'OCDE, certaines sections nécessitent un compte pour accéder aux données plus détaillées.
 - i. Accessible via API

5. **INSEE (Institut National de la Statistique et des Études Économiques)** (<https://www.insee.fr/fr/accueil>)

- a. L'INSEE publie des données statistiques officielles de la France, couvrant l'économie, la population, l'emploi, et divers autres secteurs sociaux. Les informations incluent des recensements, indicateurs économiques et rapports sectoriels nationaux et régionaux.
- b. Exemple : **Indicateur d'activité et de chiffre d'affaires** : https://catalogue-donnees.insee.fr/fr/catalogue/recherche/DS_ICA
- c. **Accès** : L'accès est libre via le site web, et une API est disponible pour des applications spécifiques.

6. **OSCAR Dataset** (<https://oscar-project.org/>)

- a. Base de données linguistique issue de sources web multilingues, OSCAR propose des corpus massifs utilisés pour le traitement automatique des langues (NLP), la traduction et la recherche en intelligence artificielle.
- b. **Accès** : <https://oscar-project.github.io/documentation/accessing/>

7. **CNet Dataset** (<https://commoncrawl.org/>)

- a. Réseau de données textuelles provenant de « Common Crawl », le CNet Dataset agrège des données textuelles issues de pages web pour des applications en NLP et machine learning.
- b. **Accès** : Disponible en téléchargement sur le site Common Crawl, souvent en format brut nécessitant un prétraitement.
- c. Cas d'usage : **Mapping french open data actors on the web with common crawl** : <https://pt.slideshare.net/slideshow/mapping-french-open-data-actors-on-the-web-with-common-crawl/14648888>

3. Pour analyser les documents et les exporter au format souhaité avec facilité et rapidité:

<https://github.com/DS4SD/docling>

4. User stories

1. *Résumé financiers*

- a. **Besoin:** Obtenir des **résumés financiers concis** pour des suivis, la culture G, des réunions avec des investisseurs, afin de communiquer les performances des entreprises efficacement.
- b. **Agent LLM:** **Extraction et synthétisation des données financières clés**, telles que le chiffre d'affaires, l'EBITA et les marges + un résumé clair et concis.
- c. **BDD:** **Section analyse financière** sous forme tabulaire ainsi que données textuelles **globales**

2. *Analyse des pratiques ESG*

- a. **Besoin:** Obtenir une **évaluation détaillée des pratiques environnementales, sociales et de gouvernance (ESG)** d'une entreprise afin d'être en accord avec ses valeurs.
- b. **Agent LLM:** Analyse de **rapports ESG** des entreprises afin d'extraire les **initiatives ESG** (les objectifs de réduction des émissions de carbone, politiques de diversité) en fournissant une **évaluation de leur conformité par rapport aux standards ESG**.
- c. **BDD:** Section initiatives durables, objectifs de réduction carbone (ex: EMR_2022), défis de la transition énergétique et les stratégies environnementales (ex: ASX_88E)

3. *Investissement & diversification portefeuille ???*

- a. **Besoin:** **Recommandation**, afin de diversifier les investissements d'un clients et/ou soit même tout en **minimisant les risques**, en intégrant des **secteurs à forte croissance**.
- b. **Agent LLM:** Répartition géographique des revenus et la diversification des produits (ex: AMEX_EMR), acquisitions stratégiques, stratégies (ex: ASX_EQT)

4. *Santé financière d'une entreprise ???*

- a. **Besoin:**

b. Agent LLM:

c. BDD:

5. Documentation RAG Vision

1. Colpali :

Il s'agit d'un **modèle de récupération de documents qui utilise des modèles de vision et de langage (VLM) pour comprendre et indexer des documents en se basant sur leur contenu visuel.**

ColPali génère des représentations multi-vecteurs des textes et des images, facilitant une interaction tardive entre les tokens de la requête et les patches d'image.



Cette approche **élimine le besoin de pipelines complexes** de reconnaissance de mise en page et d'OCR, en utilisant un seul modèle qui prend en compte à la fois le **contenu textuel et visuel** d'un document.



Modèles d'entraînement **limités en français**, utilisation de **PaliGemma entraîné majoritairement en anglais!**

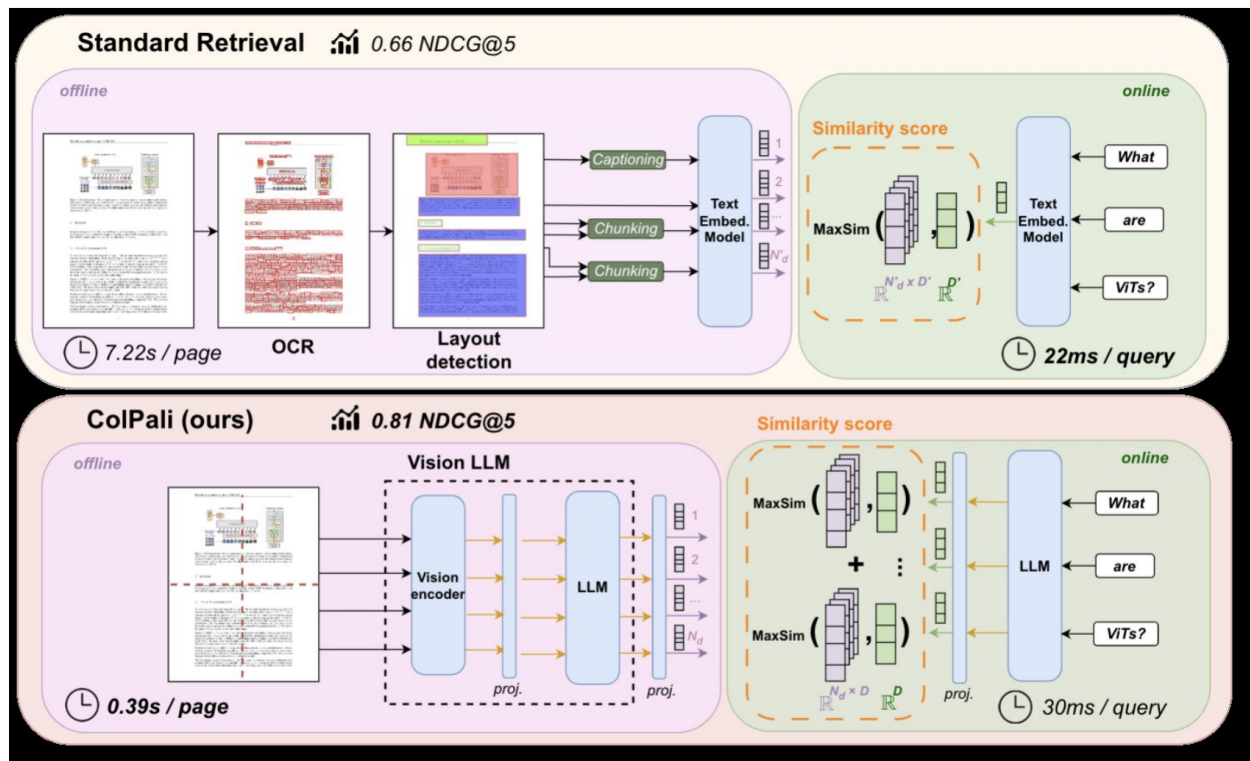


Figure 3: Fonctionnement ColPali

Architecture et Fonctionnement de ColPali

Phase d'indexation :

- ColPali encode **directement les pages du document sous forme d'images**.
- Le modèle VLM découpe chaque image en *patches* (segments visuels) qui sont traités par un transformeur de vision.
- Ces patches sont ensuite projetés comme des « tokens doux » dans un modèle de langage, générant des vecteurs de contexte riches. Une projection finale dans une dimension plus petite optimise le stockage.
- Chaque page image se voit attribuer une représentation multi-vecteurs pour les futures recherches.

Phase de requête :

- Les tokens de la requête utilisateur sont intégrés, et une opération d'interaction tardive identifie les patches d'image les plus similaires aux termes de la requête.

- La somme des scores de similarité de ces patches fournit un score global de correspondance entre la requête et le document.




Figure 4: Schéma fonctionnel

2. Utilisation de modèles VLM

- Nouvelle version de Pixtral Large (modèle MISTRAL)

	Pixtral 12B	Qwen2 7B VL	LLaVA-OV 7B	Phi-3 Vision	Phi-3.5 Vision
MMMU (CoT)	<u>52.5</u>	47.6	45.1	40.3	38.3
Mathvista (CoT)	<u>58.0</u>	54.4	36.1	36.4	39.3
ChartQA (CoT)	<u>81.8</u>	38.6	67.1	72.0	67.7
DocVQA (ANLS)	90.7	<u>94.5</u>	90.5	84.9	74.4
VQAv2 (VQA Match)	<u>78.6</u>	75.9	78.3	42.4	56.1

Figure 5: Performances vs VLM

- Qwen , Cog , Claude, Gemini, GPT 4.0 (etc)

Documentation + infos

- Papier recherche sur colpali: <https://arxiv.org/abs/2407.01449>
- Vidéo explicative et démo: https://www.youtube.com/watch?v=DI9Q60T_054&ab_channel=PromptEngineering
- Répo github très intéressant : https://github.com/merveenoyan/smol-vision/blob/main/ColPali_%2B_Qwen2_VL.ipynb

Byaldi → packages pour utiliser *Colpali* (même créateur que ragatouille)

Benchmark des performances de modèles

1. **Benchmark Vidore (Visual Document Retrieval Benchmark)** permettant d'évaluer les systèmes de récupération sur des documents visuels.



ColPali surpasse les autres modèles, en particulier pour les **tâches visuelles complexes** (InfographicVQA, ArxivQA, TabFQuAD) et **montre une meilleure performance même pour les documents textuels**.

	ArxivQ	DocQ	InfoQ	TabF	TATQ	Shift	AI	Energy	Gov.	Health.	Avg.
Unstructured Text only											
- BM25	-	34.1	-	-	44.0	59.6	90.4	78.3	78.8	82.6	-
- BGE-M3	-	28.4 _{↓5.7}	-	-	36.1 _{↓7.9}	68.5 _{↑8.9}	88.4 _{↓2.0}	76.8 _{↓1.5}	77.7 _{↓1.1}	84.6 _{↑2.0}	-
Unstructured + OCR											
- BM25	31.6	36.8	62.9	46.5	62.7	64.3	92.8	85.9	83.9	87.2	65.5
- BGE-M3	31.4 _{↓0.2}	25.7 _{↓11.1}	60.1 _{↓2.8}	70.8 _{↑24.3}	50.5 _{↓12.2}	73.2 _{↑8.9}	90.2 _{↓2.6}	83.6 _{↓2.3}	84.9 _{↑1.0}	91.1 _{↑3.9}	66.1 _{↑0.6}
Unstructured + Captioning											
- BM25	40.1	38.4	70.0	35.4	61.5	60.9	88.0	84.7	82.7	89.2	65.1
- BGE-M3	35.7 _{↓4.4}	32.9 _{↓5.4}	71.9 _{↑1.9}	69.1 _{↑33.7}	43.8 _{↓17.7}	73.1 _{↑12.2}	88.8 _{↑0.8}	83.3 _{↓1.4}	80.4 _{↓2.3}	91.3 _{↑2.1}	67.0 _{↑1.9}
Contrastive VLMs											
Jina-CLIP	25.4	11.9	35.5	20.2	3.3	3.8	15.2	19.7	21.4	20.8	17.7
Nomic-vision	17.1	10.7	30.1	16.3	2.7	1.1	12.9	10.9	11.4	15.7	12.9
SigLIP (Vanilla)	43.2	30.3	64.1	58.1	26.2	18.7	62.5	65.7	66.1	79.1	51.4
Ours											
SigLIP (Vanilla)	43.2	30.3	64.1	58.1	26.2	18.7	62.5	65.7	66.1	79.1	51.4
BiSigLIP (+fine-tuning)	58.5 _{↑15.3}	32.9 _{↑2.6}	70.5 _{↑6.4}	62.7 _{↑4.6}	30.5 _{↑4.3}	26.5 _{↑7.8}	74.3 _{↑11.8}	73.7 _{↑8.0}	74.2 _{↑8.1}	82.3 _{↑3.2}	58.6 _{↑7.2}
BiPali (+LLM)	56.5 _{↓2.0}	30.0 _{↓2.9}	67.4 _{↓3.1}	76.9 _{↑14.2}	33.4 _{↑2.9}	43.7 _{↑17.2}	71.2 _{↓3.1}	61.9 _{↓11.7}	73.8 _{↓0.4}	73.6 _{↓8.8}	58.8 _{↑0.2}
ColPali (+Late Inter.)	79.1 _{↑22.6}	54.4 _{↑24.5}	81.8 _{↑14.4}	83.9 _{↑7.0}	65.8 _{↑32.4}	73.2 _{↑29.5}	96.2 _{↑25.0}	91.0 _{↑29.1}	92.7 _{↑18.9}	94.4 _{↑20.8}	81.3 _{↑22.5}

Figure 6: Benchmark Vidore

Avec modèle prise en main RAG

Nécessité de modèles multimodal et/ou vision :

→ Le modèle est incapable d'analyser correctement les tableaux.

→ Il peut localiser la bonne page mais ne parvient pas à lire les données textuelles peu formatés!

Question: Quels sont les réserves à l'année 2010?
Réponse: 1,566,000 1,450,000 1,304,000

ADAMS RESOURCES & ENERGY, INC. AND SUBSIDIARIES

LETTER TO SHAREHOLDERS — (Continued)

Transportation

Customer demand of our petrochemical delivery services increased significantly for 2010 improving both revenues and operating earnings. Contributing to this situation is the improving United States economy coupled with export demand and relatively low natural gas prices that benefit our customer base through low feedstock costs. Industry capacity constraints also bolstered earnings by allowing rate increases as customers competed for service.

Oil and Gas

With \$4.2 million in exploration expense and property impairment charges, oil and gas operations sustained a \$1,757,000 loss in 2010. During 2010, the Company participated in the drilling of 53 wells with 41 successful and 12 dry holes. Additionally, the Company had twenty-one wells in process on December 31, 2010 with ultimate evaluation anticipated during 2011. Converting natural gas volumes to equate with crude oil volumes at a ratio of six to one, oil and gas production volumes and proved reserve changes summarized as follows on an equivalent barrel (Eq. Bbls) basis:

	2010	2009	2008
	(Eq. Bbls.)	(Eq. Bbls.)	(Eq. Bbls.)
Proved reserves — beginning of year	1,450,000	1,304,000	1,475,000
Estimated reserve additions	536,000	439,000	395,000
Production volumes	(282,000)	(267,000)	(258,000)
Revisions of previous estimates	(138,000)	(26,000)	(308,000)
Proved reserves — end of year	1,566,000	1,450,000	1,304,000

Figure 7: Pipeline simple Langchain

6. Conclusion et perspectives

1. RAG vision

Méthode	Avantages	Inconvénients	Ressources
ColPali + VLM/LLM	- Pipeline simple - Multimodal (texte, image, tableaux) -Très performant (cf. Benchmark) -Peu coûteux en performance - Explicabilité +++	- Difficulté en Français - Temps query	
Méthodes classiques (Unstructured)	-Multimodal -Performant sur certaines tâches - Query rapide	- Pipeline fastidieux - Difficulté à comprendre structure et liens	
BiPali	- Génère des réponses enrichies - Multimodal	- Plus coûteux en termes de ressources (LLM intégré) -Dépend du fine-tuning du LLM - Lent sur grands corpus	

SigLIP	-Compatible texte + visuel -Simple à implémenté - Moins coûteux que BiPali	- Pas de réponses riches - Non optimal pour raisonnement complexe	
---------------	--	---	--

2. Fine tuning de LLM

Possibilités plus vastes:

- Fine tuner Pixtral par exemple (car dans consensus)
- SigLip fine tuner données financières?
- Qwen , Cog , Claude, Gemini, LLama ,etc

Avantages	Inconvénients
Permet de spécialiser un modèle sur un domaine précis	Grandes quantités de données annotée
Réduit la dépendance au pipeline RAG	Entraînement coûteux
Génère des réponses adaptées à des cas d'usage spécifiques	Moins performant sans bonnes données d'entraînement

Répartition et objectifs:

All tasks +						New	
N° Task ID	Task name	Status	Assignee	Due	Priority		
AMH-15	Prise en main RAG langchain	Done	Gabriel Trier R Rayane Bouaita L Lucas Tramonte	November 7, 2024	High		
AMH-14	Recherche data set open source	Done	Gabriel Trier R Rayane Bouaita L Lucas Tramonte	November 7, 2024	Medium		
AMH-11	Appréhender le jeu de données	Done	Lucas Tramonte R Rayane Bouaita G Gabriel Trier	November 11, 2024	High		
AMH-8	Statistique Dataset	Done	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	November 14, 2024	High		
AMH-10	User story - Cas d'usage	In progress	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	November 21, 2024	Medium		
AMH-12	Documentation RAG Vision	In progress	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	November 22, 2024	Medium		
AMH-22	Statistique Zipf law	In progress	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	December 3, 2024			
AMH-16	Accès aux ressources GPU	Blockage			High		
AMH-9	Adapter l'approche RAG avec Colpali	Blockage			High		
AMH-13	Schéma fonctionnel - Pipeline RAG	Not started	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	November 25, 2024	Medium		