

Compte rendu récapitulatif

07/11/2024



Ce qui a été fait :

Acculturation RAG :

- Compréhension des étapes d'une pipeline de RAG
- Comment utiliser LangChain pour mettre en place la pipeline ?

Pour construire un **système RAG avec LangChain**, nous avons besoins des composants suivants :

- **Document Loaders** : Chargent les documents à partir de différentes sources (PDF, sites web, bases de données, etc.).
- **Text Splitters** : Divisent les documents en morceaux (chunks) plus petits pour une manipulation plus efficace.
- **Embeddings** : Convertissent le texte en vecteurs numériques pour permettre la recherche sémantique.
- **Vector Stores** : Stockent les embeddings pour une récupération rapide.
- **Retrievers** : Récupèrent les documents pertinents en fonction d'une requête.
- **LLMs (Language Models)** : Génèrent des réponses basées sur les documents récupérés.
- **Chains** : Orchestrent le flux d'informations entre les composants.



Link vers le notebook :

Benchmark jeu de données financières

1. Registre National des Entreprises (RNE) de l'INPI

(https://data.inpi.fr/content/editorial/Acces_API_Entreprises)

- a. Offrent un accès libre et gratuit aux informations légales et financières des entreprises françaises (bilans, comptes de résultats, immobilisations et provisions).
- Les principaux droits et obligations liés à l'utilisation de ces données sont :
 1. **Liberté de réutilisation** : Droit de reproduire, modifier, distribuer et exploiter les données, que ce soit à des fins commerciales ou non.
 2. **Mention de la source** : Obligation de citer l'INPI comme source et d'indiquer la date de mise à jour des données utilisées.
 3. **Respect des données personnelles** : Nécessité de se conformer aux règles du RGPD pour garantir une utilisation légale et éthique des données personnelles.
- Demande d'accès nécessaire pour **API** et/ou **SFTP**
- **Etude qualitative et quantitative à réaliser!**

2. Finance Alpaca - Hugging Face

(<https://huggingface.co/datasets/gbharti/finance-alpaca>)

3. Financial Reports sec - Hugging Face

(<https://huggingface.co/datasets/JanosAudran/financial-reports-sec>)

Autres Jeux de données

1. European Central Bank Statistical Data Warehouse (SDW) :
(<https://data.ecb.europa.eu/data/datasets>)
2. OECD Economic Outlook: (<https://www.oecd.org/en/topics/sub-issues/economic-outlook.html>)
3. INSEE (Institut National de la Statistique et des Études Économiques):
(<https://www.insee.fr/fr/accueil>)
4. OSCAR Dataset (**O**pen **S**uper-large **C**rawled **A**ggregated co**R**pus) :
(<https://oscar-project.org/>)
5. CNet Dataset : (<https://commoncrawl.org/>)

Répartition et objectifs:

N° Task ID	Aa Task name	Status	Assignee	Due	Priority
AMH-15	🔗 Prise en main RAG langchain	Done	👤 Gabriel Trier 👤 Rayane Bouaita 👤 Lucas Tramonte	November 7, 2024	High
AMH-14	📄 Recherche data set open source	In progress	👤 Gabriel Trier 👤 Rayane Bouaita 👤 Lucas Tramonte	November 7, 2024	Medium
AMH-11	📊 Appréhender le jeu de données	In progress	👤 Lucas Tramonte 👤 Rayane Bouaita 👤 Gabriel Trier	November 11, 2024	High
AMH-8	📊 Statistique Dataset	In progress	👤 Rayane Bouaita 👤 Lucas Tramonte 👤 Gabriel Trier	November 14, 2024	High
AMH-10	👤 User story - Cas d'usage	In progress	👤 Rayane Bouaita 👤 Lucas Tramonte 👤 Gabriel Trier	November 13, 2024	Medium
AMH-12	📄 Documentation RAG Vision	Not started	👤 Rayane Bouaita 👤 Lucas Tramonte 👤 Gabriel Trier	November 14, 2024	
AMH-13	🔄 Schéma fonctionnel - Pipeline RAG	Not started	👤 Rayane Bouaita 👤 Lucas Tramonte 👤 Gabriel Trier	November 14, 2024	
AMH-9	🔧 Adapter l'approche RAG	Not started			