



CentraleSupélec

Point de mi-parcours

Projet Infonum 59 - IA pour l'analyse des résultats financiers

16/01/2025

Gabriel Trier
Lucas Tramonte
Rayane Bouaita

Céline Hudelot
Charles Moslonka
Hicham Randrianarivo

Sommaire

- Introduction
- État de l'art
- Schéma d'ensemble du projet
- Analyse des choix techniques
- État d'avancement
- Problèmes rencontrés
- Conclusion

Introduction

- **Contexte:**

- Projet entre le centre de recherche d'**Artefact** et le laboratoire **MICS**, dans le cadre de l'initiative de **France 2030**
- Objectif national: renforcer l'écosystème français de l'IA générative en créant des communs numériques partagés

- **Enjeux:**

- Gestion de données complexes (textuelles, tableaux, graphiques)
- Analyse des rapports financiers via l'IA tout en assurant la fiabilité et la transparence.
- Respecter les exigences ESG (Environmental, Social, and Governance)

- **Objectifs:**

- Publier un dataset open-source de rapport financier
- Développer un agent basé sur des LLMs open source

Introduction

- **Contexte:**

- Projet entre le centre de recherche d'**Artefact** et le laboratoire **MICS**, dans le cadre de l'initiative de **France 2030**
- Objectif national: renforcer l'écosystème français de l'IA générative en créant des communs numériques partagés

- **Enjeux:**

- Gestion de données complexes (textuelles, tableaux, graphiques)
- Analyse des rapports financiers via l'IA tout en assurant la fiabilité et la transparence
- Respecter les exigences ESG (Environmental, Social, and Governance)

- **Objectifs:**

- Publier un dataset open-source de rapport financier
- Développer un agent basé sur des LLMs open source

Introduction

- **Contexte:**

- Projet entre le centre de recherche d'**Artefact** et le laboratoire **MICS**, dans le cadre de l'initiative de **France 2030**
- Objectif national: renforcer l'écosystème français de l'IA générative en créant des communs numériques partagés

- **Enjeux:**

- Gestion de données complexes (textuelles, tableaux, graphiques)
- Analyse des rapports financiers via l'IA tout en assurant la fiabilité et la transparence
- Respecter les exigences ESG (Environmental, Social, and Governance)

- **Objectifs:**

- Publier un dataset open-source de rapport financier
- Développer un agent basé sur des LLMs open source

État de l'art

- **LLMs Finance:**

- BloombergGPT (propriétaire, spécialisé dans la finance, performant).
- FinBERT (open-source, spécialisé dans la finance).

- **Base de données:**

- Finance Alpaca
- Financial Reports SEC Dataset
- OSCAR Dataset (traduction multilingue)

- **Domain Specialization:**

- Fine-tuning de LLMs sur des données financières
- Combinaison de RAG et de VLM

État de l'art

- **LLMs Finance:**

- BloombergGPT (propriétaire, spécialisé dans la finance, performant)
- FinBERT (open-source, spécialisé dans la finance)

- **Base de données:**

- Finance Alpaca
- Financial Reports SEC Dataset
- OSCAR Dataset (traduction multilingue)

- **Domain Specialization:**

- Fine-tuning de LLMs sur des données financières
- Combinaison de RAG et de VLM

État de l'art

- **LLMs Finance:**

- BloombergGPT (propriétaire, spécialisé dans la finance, performant)
- FinBERT (open-source, spécialisé dans la finance)


- **Base de données:**

- Finance Alpaca
- Financial Reports SEC Dataset
- OSCAR Dataset (traduction multilingue)

- **Domain Specialization:**

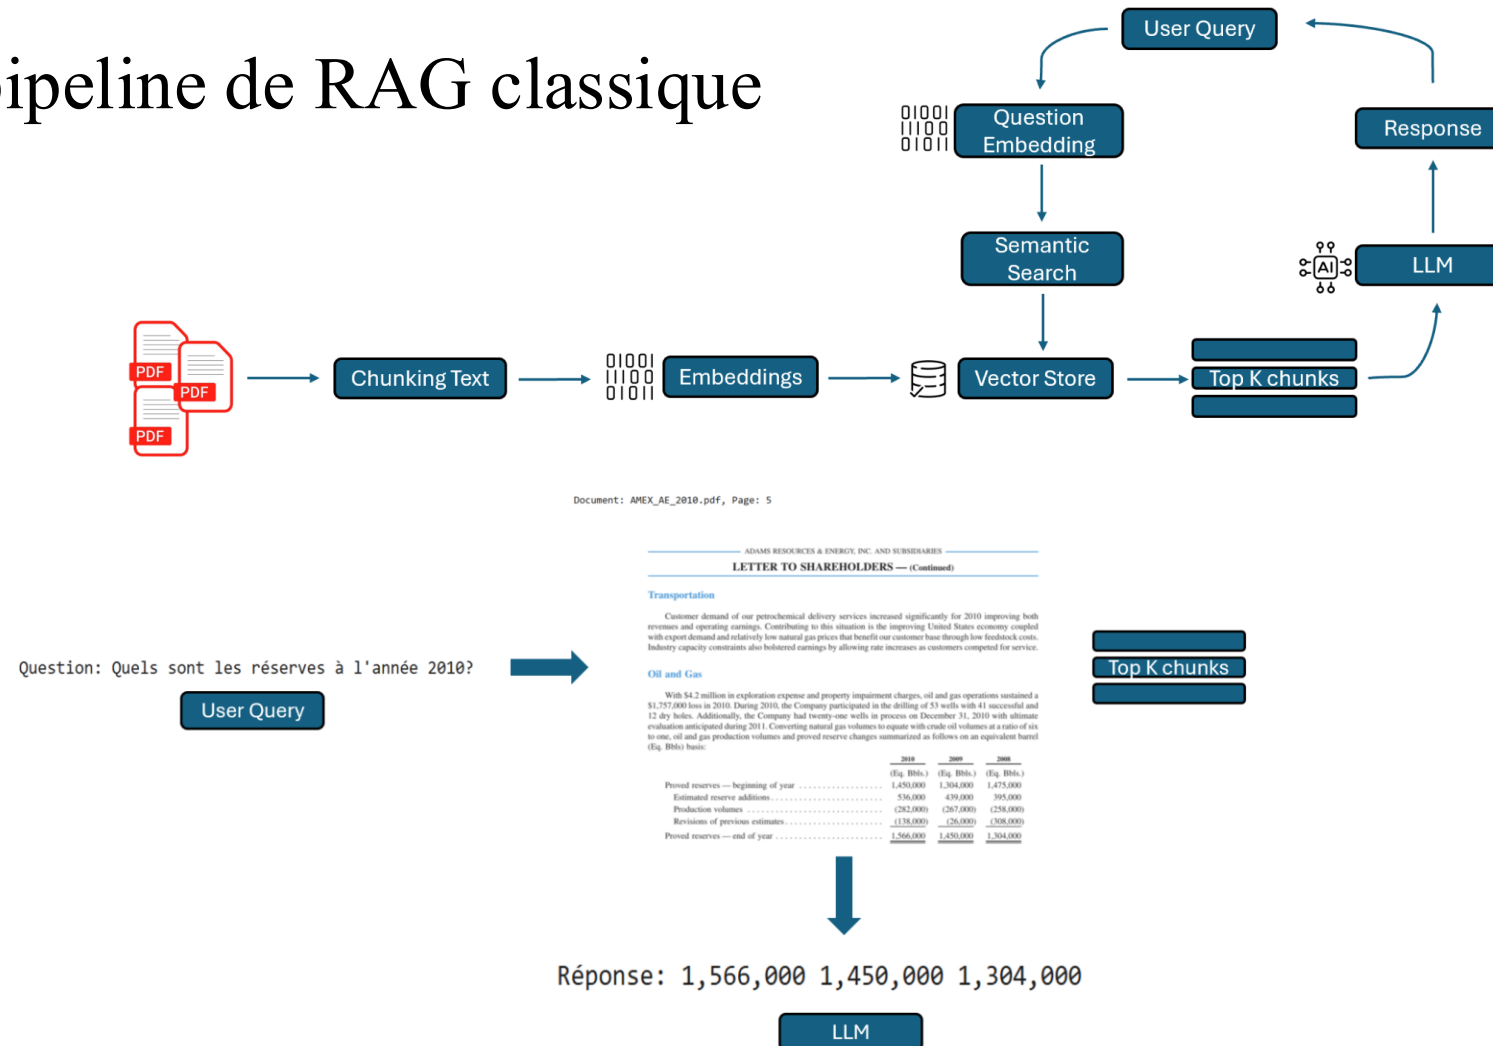
- Fine-tuning de LLMs sur des données financières
- Combinaison de RAG et de VLM

Schéma d'ensemble




Analyse des choix techniques

- Première pipeline de RAG classique





Analyse des choix techniques

- **RAG Vision – Colpali**
 - Pipeline simplifiée
 - Récentes avancées sur VLM et ViT




Analyse des choix techniques

- **Indexing – Colpali**
 - ViT: SigLIP-So400m
 - VLM: PaliGemma-2B
 - Représentation multi vecteurs
- **Retrieval**
 - Late interaction mechanism




Analyse des choix techniques

- Intégration – Colpali et VLM pour génération



État d'avancement

- Exploration des solutions (LangChain, ColPali)
- Premiers tests sur nos données financières + dataset d'évaluation
- Création d'un pipeline (ColPali + Qwen-VL)



Sorties pipeline



« The operating cash flow of Emerson in 2023 was \$2.7 billion »

Token #8: `'\_cash'`, MaxSim score: 0.70

CASH FLOW	2021	2022	2023
Operating Cash Flow	\$2,456	2,048	2,726
Percent of sales	19.0%	14.8%	19.0%
Capital Expenditures	\$404	299	363
Percent of sales	3.1%	2.2%	2.4%
Free Cash Flow (Operating Cash Flow less Capital Expenditures)	\$2,054	1,749	2,363
Percent of sales	15.9%	12.7%	15.6%
Operating Working Capital	\$457	900	1,283
Percent of sales	3.5%	7.2%	8.5%

Operating cash flow from continuing operations for 2023 was \$2.7 billion, an increase of \$678, or 33 percent compared with 2022, reflecting higher earnings (excluding the impacts in both years from the Vertiv subordinated interest gains and higher Heritage AspenTech intangibles amortization in the current year). Operating cash flow included approximately \$310 generated by AspenTech. Operating cash flow from continuing operations of \$2.0 billion in 2022 decreased 17 percent compared to \$2.5 billion in 2021, reflecting higher working capital due to increased sales and ongoing supply chain constraints.


At September 30, 2023, operating working capital as a percent of sales was 8.5 percent compared with 7.2 percent in 2022 and 3.5 percent in 2021. Operating working capital remained elevated in 2023 due to higher inventory levels to support sales growth and higher receivables. The increase for 2022 compared to 2021 was due to higher inventory levels to support sales growth and reflecting supply chain constraints. In addition, the Heritage AspenTech acquisition increased operating working capital by approximately \$250 in 2022. As of September 30, 2023, Emerson's cash and equivalents totaled \$8.1 billion, reflecting the after-tax proceeds related to the Copeland transaction, which were used along with other available liquidity to fund the National Instruments transaction subsequent to year-end (see the Leverage/Capitalization section for further discussion of Emerson's post-close financial position). Going forward, Copeland is not expected to issue dividends to the Company but will distribute cash for the Company to pay its share of U.S. taxes. The Company's cash also includes approximately \$120 attributable to AspenTech which is intended to be used for its own purposes and is not available to return to Emerson shareholders.

Free cash flow from continuing operations (operating cash flow less capital expenditures) was \$2,363 in 2023, up 35 percent, reflecting the increase in operating cash flow. Free cash flow from continuing operations was \$1,749 in 2022, compared with \$2,054 in 2021. Net cash paid in connection with acquisitions was \$705, \$5,702 and \$1,592 in 2023, 2022 and 2021, respectively.

Exemple similarity_map token 'cash'

État d'avancement

- Mise en place interface Streamlit



Problèmes rencontrés

- Contraintes de mémoire GPU
- Intégration complexe entre ColPali et VLMs
- Courbe d'apprentissage élevée pour RAG
- Problème de mémoire sur Streamlit avec Remote Desktop DCE :
<https://dev.dce-cs.fr>

Conclusion

- **Résumé**

- Intégration d'un pipeline RAG Vision (ColPali + Qwen-VL)
- Premiers tests sur une partie des données financières

- **Prochaines étapes**

- Mise en œuvre de métriques d'évaluation
- Scaling des données PDF
- Combinaison de pipeline RAG classique et RAG vision
- Interface Streamlit à adapter

Conclusion

- **Résumé**

- Intégration d'un pipeline RAG Vision (ColPali + Qwen-VL)
- Premiers tests sur une partie des données financières

- **Prochaines étapes**

- Mise en œuvre de métriques d'évaluation
- Scaling des données PDF
- Combinaison de pipeline RAG classique et RAG vision
- Interface Streamlit à adapter