

Suivi de projet

MICS X Artefact Research Lab

Gabriel, Lucas & Rayane






Table des matières

01

Apprehender jeu de
données

02

Analyse statistique

03

Users stories

04

Recherche data set
open source

05

RAQ Vision

06

Conclusion



1. Appréhender jeu de données



Document Number	Number of Pages	Textuelles	Graphiques	Tableaux	Language	Source	Type d'information	date	Audit
35	66	✓	✓	✓	EN	Emerson	Report annuel	2014 KPMG	
36	66	✓	✓	✓	EN	Emerson	Report annuel	2015 KPMG	
37	24	✓	✓	✓	EN	Emerson	Report annuel	2016 KPMG	
38	92	✓	✓	✓	EN	Emerson	Report annuel	2017 KPMG	
39	68	✓	✓	✓	EN	Emerson	Report annuel	2018 KPMG	
40	71	✓	✓	✓	EN	Emerson	Report annuel	2019 KPMG	
41	80	✓	✓	✓	EN	Emerson	Report annuel	2020 KPMG	
42	88	✓	✓	✓	EN	Emerson	Report annuel	2021 KPMG	
43	99	✓	✓	✓	EN	Emerson	Report annuel	2022 KPMG	
44	96	✓	✓	✓	EN	Emerson	Report annuel	2023 KPMG	
45	75	✓	□	✓	EN	Energy	Report annuel	2014 EY	
46	75	✓	□	✓	EN	Energy	Report annuel	2014 Doublons	
47	61	✓	□	✓	EN	Energy	Report annuel	2015 BDO	
48	71	✓	□	✓	EN	Energy	Report annuel	2016 BDO	
49	73	✓	□	✓	EN	Energy	Report annuel	2017 BDO	
50	78	✓	□	✓	EN	Energy	Report annuel	2018 BDO	
51	71	✓	□	✓	EN	Energy	Report annuel	2019 BDO	
52	76	✓	□	✓	EN	Energy	Report annuel	2020 BDO	
53	77	✓	□	✓	EN	Energy	Report annuel	2021 BDO	
54	80	✓	□	✓	EN	Energy	Report annuel	2022 BDO	
55	90	✓	□	✓	EN	Energy	Report annuel	2023 BDO	
56	68	✓	✓	✓	EN	Equity Trustees	Report annuel	2005 Deloitte	
57	108	✓	✓	✓	EN	Equity Trustees	Report annuel	2006 Deloitte	
58	112	✓	✓	✓	EN	Equity Trustees	Report annuel	2007 Deloitte	
59	84	✓	□	✓	EN	Equity Trustees	Report annuel	2008 Deloitte	
60	80	✓	□	✓	EN	Equity Trustees	Report annuel	2009 Deloitte	
61	80	✓	□	✓	EN	Equity Trustees	Report annuel	2010 Deloitte	
62	76	✓	□	✓	EN	Equity Trustees	Report annuel	2011 Deloitte	
63	80	✓	□	✓	EN	Equity Trustees	Report annuel	2012 Deloitte	
64	80	✓	□	✓	EN	Equity Trustees	Report annuel	2013 Deloitte	
65	84	✓	□	✓	EN	Equity Trustees	Report annuel	2014 Deloitte	
66	76	✓	□	✓	EN	Equity Trustees	Report annuel	2015 Deloitte	
67	88	✓	✓	✓	EN	Equity Trustees	Report annuel	2016 Deloitte	
68	57	✓	✓	✓	EN	Equity Trustees	Report annuel	2017 Deloitte	
69	120	✓	✓	✓	EN	Equity Trustees	Report annuel	2018 Deloitte	
70	128	✓	✓	✓	EN	Equity Trustees	Report annuel	2019 Deloitte	

Cf. *Artefact BDD* (Notion ou fichiers équipe teams)

- Répartition des 107 documents
- Analyse du contenu, **année**, type de document, source, **nombre de pages**, langues
- Informations **graphiques**, **tabulaires**, etc



Analyse statistique

78,5

Moyenne de pages ensemble documents

79

Documents infos
graphiques/tableaux

79,8

Moyenne de pages

Graphiques	(Tous)				
Étiquettes de lignes	Moyenne de Number of Pages	Nbr de Graphiques	Nbr de Tableaux	Nbr d'info textuelles	
1999	56	1	1	1	1
2000	60	1	1	1	1
2001	47,5	2	2	2	2
2002	61	2	2	2	2
2003	66	2	2	2	2
2004	61,5	2	2	2	2
2005	67,33333333	3	3	3	3
2006	80,66666667	3	3	3	3
2007	72,75	4	4	4	4
2008	65	4	4	4	4
2009	76,25	4	4	4	4
2010	71,75	4	4	4	4
2011	67	5	5	5	5
2012	68,6	5	5	5	5
2013	79	5	5	5	5
2014	79	6	6	6	6
2015	73,5	6	6	6	6
2016	71,83333333	6	6	6	6
2017	76,4	5	5	5	5
2018	84	5	5	5	5
2019	84	6	6	6	6
2020	94	6	6	6	6
2021	93,57142857	7	7	7	7
2022	95,57142857	7	7	7	7
2023	102,1666667	6	6	6	6
Total général	78,51401869	107	107	107	107

2. Recherche data set open source

01

Finance Alpaca (Hugging Face)

Exemple de Requête: Où devrais-je
investir mon argent ?
Data set contient les bonnes réponses

02

Financial Reports sec (Hugging Face)

Rapports financiers des entreprises
cotées aux États-Unis

03

OSCAR Dataset

Corpus massifs utilisés pour
la traduction



3. Users stories



Résumé financiers

Agent LLM:

- **Extraction** et **synthétisation** des données financières clés
- Chiffre d'affaires, EBITA et les marges, etc

BDD:

- Section **analyse financière forme tabulaire** + données textuelles globales



Analyse des pratiques ESQ

Agent LLM:

- **Rapports ESG** (objectifs, initiatives, politique diversité)
- **Evaluation** des pratiques/conformité

BDD:

- Section **initiatives durables** + objectifs réduction carbone
- Stratégies ,etc



Investissement & diversification portefeuille

Agent LLM:


- **Recommandation** en minimisant les risques
- Intégration **secteurs forte croissance**

BDD:

- **Répartition géographique** des revenus + **diversification** des produits
- **Acquisitions** stratégiques,

4. Simulation Pipeline initiale

Question: Quels sont les réserves à l'année 2010?



Réponse: 1,566,000 1,450,000 1,304,000

- **Incapacité d'analyser** correctement les tableaux
- **Bonne localisation** de la page
- **Besoin de modèles multimodal et/ou vision**

Document: AMEX_AE_2010.pdf, Page: 5

ADAMS RESOURCES & ENERGY, INC. AND SUBSIDIARIES
LETTER TO SHAREHOLDERS — (Continued)

Transportation

Customer demand of our petrochemical delivery services increased significantly for 2010 improving both revenues and operating earnings. Contributing to this situation is the improving United States economy coupled with export demand and relatively low natural gas prices that benefit our customer base through low feedstock costs. Industry capacity constraints also bolstered earnings by allowing rate increases as customers competed for service.

Oil and Gas

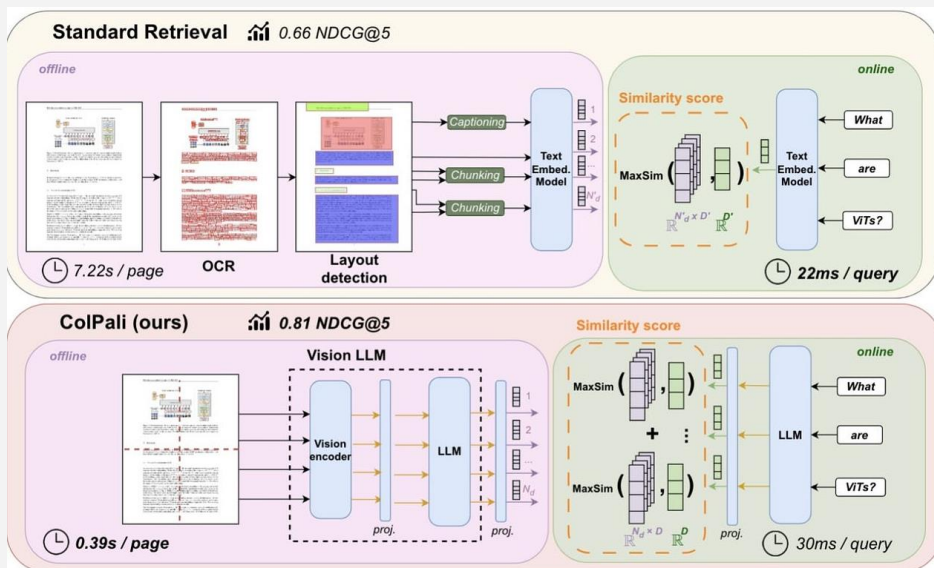
With \$4.2 million in exploration expense and property impairment charges, oil and gas operations sustained a \$1,757,000 loss in 2010. During 2010, the Company participated in the drilling of 53 wells with 41 successful and 12 dry holes. Additionally, the Company had twenty-one wells in process on December 31, 2010 with ultimate evaluation anticipated during 2011. Converting natural gas volumes to equate with crude oil volumes at a ratio of six to one, oil and gas production volumes and proved reserve changes summarized as follows on an equivalent barrel (Eq. Bbls) basis:

	2010	2009	2008
	(Eq. Bbls.)	(Eq. Bbls.)	(Eq. Bbls.)
Proved reserves — beginning of year	1,450,000	1,304,000	1,475,000
Estimated reserve additions	536,000	439,000	395,000
Production volumes	(282,000)	(267,000)	(258,000)
Revisions of previous estimates	(138,000)	(26,000)	(308,000)
Proved reserves — end of year	<u>1,566,000</u>	<u>1,450,000</u>	<u>1,304,000</u>



5. Modèles RAQ VISION

ColPali



✓ Cette approche élimine le besoin de pipelines complexes de reconnaissance de mise en page et d'OCR, en utilisant un seul modèle qui prend en compte à la fois le contenu textuel et visuel d'un document.

✗ Modèles d'entraînement limités en français, utilisation de PaliGemma entraîné majoritairement en anglais!




Architecture/fonctionnement

Phase d'indexation

- **Encodage** pages directement **sous format d'image**
- Image **découpée en *patches*** (segments visuels) par modèles VLM
- Patches **projetés dans modèle de langage** → vecteurs de contexte riches
- Projection finale dans dimension plus petite
- **Représentation multi-vecteurs pour futures recherches**

Phase de requête

- Tokens utilisateur intégré
- **Opération tardive compars patches/ requête**
- **Somme score de similarité patches** → score global de correspondance



Performances Colpali

	ArxivQ	DocQ	InfoQ	TabF	TATQ	Shift	AI	Energy	Gov.	Health.	Avg.
Unstructured Text only											
- BM25	-	34.1	-	-	44.0	59.6	90.4	78.3	78.8	82.6	-
- BGE-M3	-	28.4 _{↓5.7}	-	-	36.1 _{↓7.9}	68.5 _{↑8.9}	88.4 _{↓2.0}	76.8 _{↓1.5}	77.7 _{↓1.1}	84.6 _{↑2.0}	-
Unstructured + OCR											
- BM25	31.6	36.8	62.9	46.5	62.7	64.3	92.8	85.9	83.9	87.2	65.5
- BGE-M3	31.4 _{↓0.2}	25.7 _{↓11.1}	60.1 _{↓2.8}	70.8 _{↑24.3}	50.5 _{↓12.2}	73.2 _{↑8.9}	90.2 _{↓2.6}	83.6 _{↓2.3}	84.9 _{↑1.0}	91.1 _{↑3.9}	66.1 _{↑0.6}
Unstructured + Captioning											
- BM25	40.1	38.4	70.0	35.4	61.5	60.9	88.0	84.7	82.7	89.2	65.1
- BGE-M3	35.7 _{↓4.4}	32.9 _{↓5.4}	71.9 _{↑1.9}	69.1 _{↑33.7}	43.8 _{↓17.7}	73.1 _{↑12.2}	88.8 _{↑0.8}	83.3 _{↓1.4}	80.4 _{↓2.3}	91.3 _{↑2.1}	67.0 _{↑1.9}
Contrastive VLMs											
Jina-CLIP	25.4	11.9	35.5	20.2	3.3	3.8	15.2	19.7	21.4	20.8	17.7
Nomic-vision	17.1	10.7	30.1	16.3	2.7	1.1	12.9	10.9	11.4	15.7	12.9
SigLIP (Vanilla)	43.2	30.3	64.1	58.1	26.2	18.7	62.5	65.7	66.1	79.1	51.4
Ours											
SigLIP (Vanilla)	43.2	30.3	64.1	58.1	26.2	18.7	62.5	65.7	66.1	79.1	51.4
BiSigLIP (+fine-tuning)	58.5 _{↑15.3}	32.9 _{↑2.6}	70.5 _{↑6.4}	62.7 _{↑4.6}	30.5 _{↑4.3}	26.5 _{↑7.8}	74.3 _{↑11.8}	73.7 _{↑8.0}	74.2 _{↑8.1}	82.3 _{↑3.2}	58.6 _{↑7.2}
BiPali (+LLM)	56.5 _{↓2.0}	30.0 _{↓2.9}	67.4 _{↓3.1}	76.9 _{↑14.2}	33.4 _{↑2.9}	43.7 _{↑17.2}	71.2 _{↓3.1}	61.9 _{↓11.7}	73.8 _{↓0.4}	73.6 _{↓8.8}	58.8 _{↑0.2}
<i>ColPali</i> (+Late Inter.)	79.1 _{↑22.6}	54.4 _{↑24.5}	81.8 _{↑14.4}	83.9 _{↑7.0}	65.8 _{↑32.4}	73.2 _{↑29.5}	96.2 _{↑25.0}	91.0 _{↑29.1}	92.7 _{↑18.9}	94.4 _{↑20.8}	81.3 _{↑22.5}

Benchmark Vidore (Visual Document Retrieval Benchmark)

- **Surpasse** autres modèles pour **tâches visuelles complexes** (InfographicVQA, ArxivQA, TabFQuAD)
- **Meilleure performance** pour **les documents textuels.**



7. Pistes d'implémentation

1. RAG VISION

Méthode	Avantages	Inconvénients	Ressource
ColPali + VLM/LLM	- Pipeline simple - Multimodal (texte, image, tableaux) - Très performant (cf. Benchmark) - Peu coûteux en performance - Explicabilité +++	- Difficulté en Français - Temps query	- LocalGPT - SmolVision
Méthodes classiques (Unstructured)	- Multimodal - Performant sur certaines tâches - Query rapide	- Pipeline fastidieux - Difficulté à comprendre structure et liens	
SigLIP	- Compatible texte + visuel - Simple à implémenté - Moins coûteux que BiPali	- Pas de réponses riches - Non optimal pour raisonnement complexe	



7. Pistes d'implémentation

2. Fine tuning modèles LLM

Avantages	Inconvénients
Permet de spécialiser un modèle sur un domaine précis	Grandes quantités de données annotées
Réduit la dépendance au pipeline RAQ.	Entraînement coûteux
Génère des réponses adaptées à des cas d'usage spécifiques	Moins performant sans bonnes données d'entraînement

Vastes possibilités :

- Fine tuner Pixtral
- SigLip fine tuner données financières?
- Qwen , Cog , Claude, Gemini, Llama ,etc



Conclusion

Nombreuses pages/document

- Chunking par page

Informations tabulaires graphiques a exploité

- Besoin de RAG Vision / VLM

Type d'informations exploitables

- Indicateurs de **performance financière**
- **Plans stratégiques** et initiatives de croissance
- **Tendances sectorielles** + conditions de marché
- **Engagement ESG** —> ex: Neutralité carbone *d'Emerson* et *d'Equity Trustees*
- Gestion des **risques** et **gouvernance**

8. Prochaines étapes

N° Task ID	Aa Task name	Status	Assignee	Due	Priority
AMH-15	🔗 Prise en main RAG langchain	Done	G Gabriel Trier R Rayane Bouaita L Lucas Tramonte	7 novembre 2024	High
AMH-14	📊 Recherche data set open source	Done	G Gabriel Trier R Rayane Bouaita L Lucas Tramonte	7 novembre 2024	Medium
AMH-11	📄 Appréhender le jeu de données	Done	L Lucas Tramonte R Rayane Bouaita G Gabriel Trier	11 novembre 2024	High
AMH-8	📊 Statistique Dataset	Done	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	14 novembre 2024	High
AMH-10	👤 User story - Cas d'usage	In progress	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	21 novembre 2024	Medium
AMH-12	📄 Documentation RAG Vision	In progress	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	22 novembre 2024	Medium
AMH-16	⚙️ Accès aux ressources GPU	Blocage			High
AMH-9	▼ 🔄 Adapter l'approche RAG avec Colpali	Blocage			High
AMH-19	1 Setup DCE CentralSupélec	Not started			
AMH-20	2 Tester Colpali/Colqwen avec VLM	Not started			
AMH-21	? Comment tester leurs performances?	Not started			
+ Nouvelle page imbriquée					
AMH-13	🔗 Schéma fonctionnel - Pipeline RAG	Not started	R Rayane Bouaita L Lucas Tramonte G Gabriel Trier	25 novembre 2024	Medium